

Predicción de presión del pass rush de la NFL al momento del snap

Informe técnico

Autor: Francisco Miguel Fonseca Martínez

Fecha de evaluación: 17 de agosto de 2026

Repositorio: [nfl-pressure-prediction](#)

Commit de la evaluación final: [57b088e41425b18c844e18cd34ba6cb73f8dae7e](#)

Estado del proyecto: La evaluación final fuera de tiempo se completó sobre la semana 8 de la NFL sin realizar cambios posteriores al test en el modelo, las variables, los hiperparámetros, la calibración o el umbral de clasificación.

Resumen ejecutivo

Este proyecto desarrolla y valida una solución de Machine Learning que estima, al momento del snap, la probabilidad de que un pass rusher individual genere presión sobre el quarterback más adelante en la jugada.

En términos de fútbol americano, un **pass rusher** es un jugador defensivo que intenta alcanzar o incomodar al quarterback, es decir, al jugador ofensivo que normalmente recibe el balón y realiza el pase. Una **presión** se define a partir de las etiquetas de PFF como al menos un hurry, un golpe al quarterback o un sack. El modelo produce una predicción por cada combinación de pass rusher y jugada utilizando únicamente información disponible cuando el balón entra en juego.

El análisis utilizó datos de tracking de la NFL y datos de scouting de PFF correspondientes a las semanas 1 a 8. Después de validar los datos y excluir jugadas sin un snap manual válido, la tabla analítica final contuvo:

- 36,259 observaciones de pass rushers.
- 8,531 jugadas únicas, identificadas mediante `gameId + playId`.
- 4,214 resultados positivos de presión.
- Una prevalencia general de presión de 11.622%.
- 51 predictores elegibles: 50 variables numéricas de tracking y una variable categórica de alineación.

Se utilizó un diseño temporal estricto:

Propósito	Semanas NFL	Filas	Jugadas únicas	Positivos	Tasa de presión
Entrenamiento inicial	1-6	27,950	6,587	3,283	11.746%
Validación y selección del umbral	7	3,865	913	427	11.048%
Test final no utilizado previamente	8	4,444	1,031	504	11.341%

Se conservó un pipeline de regresión logística sin ponderación de clases en lugar de candidatos más complejos de Extra Trees y histogram gradient boosting. Extra Trees produjo una mejora marginal de apenas 0.001790 en average precision sobre validación, y el intervalo bootstrap de 95% para esa ganancia incluyó el cero. Por lo tanto, la evidencia no justificó la complejidad adicional.

El umbral de clasificación se seleccionó exclusivamente sobre la semana 7 maximizando F1 y se bloqueó permanentemente en 0.12485514806532311. Posteriormente, el modelo seleccionado se clonó y se ajustó una sola vez utilizando las semanas 1-7, antes de acceder a la semana 8.

El desempeño final de la semana 8 fue:

Métrica	Resultado semana 8
Average precision	0.157750
ROC-AUC	0.596890
Log loss	0.347812
Precision	0.158940
Recall	0.476190
F1	0.238332
Specificity	0.677665
Tasa real de presión	0.113411
Tasa de predicciones positivas	0.339784

El average precision final fue 1.391 veces la prevalencia de la semana 8. El decil con puntuaciones más altas presentó una tasa observada de presión de 19.101%, equivalente a 1.684 veces la prevalencia del test.

Los resultados respaldan una **capacidad de ranking modesta pero temporalmente estable**. El modelo puede ayudar a priorizar pass rushers para revisión o análisis posterior, pero su baja precisión y elevado número de falsos positivos impiden considerarlo un detector autónomo de alta confianza.

1. Definición del problema

1.1 Pregunta analítica

El proyecto responde la siguiente pregunta:

Utilizando únicamente información de tracking de los jugadores y el balón disponible al momento del snap, ¿puede un modelo ordenar a los pass rushers según su probabilidad de generar presión sobre el quarterback?

Se trata de un problema de clasificación probabilística binaria:

$$[P(\text{pressure}=1 \mid X_{\{\text{snap}\}})]$$

donde:

- `pressure = 1` indica un hurry, hit o sack registrado por PFF.
- `pressure = 0` indica que ninguno de esos eventos fue registrado.
- $(X_{\{\text{snap}\}})$ contiene exclusivamente variables disponibles al momento del snap.

1.2 Unidad de análisis

El grano analítico es un pass rusher dentro de una jugada. Su llave única es:

```
gameId + playId + nflId
```

Esta distinción es importante porque una misma jugada puede contener varios pass rushers. Cada jugador elegible recibe una probabilidad y una clasificación individual. Una jugada debe identificarse mediante `gameId + playId`, ya que `playId` por sí solo puede repetirse en diferentes partidos.

1.3 Usos previstos y excluidos

La probabilidad puede utilizarse para ordenar pass rushers, priorizar observaciones para revisión de video o análisis, estudiar descriptivamente la geometría inicial de la jugada o servir como una entrada dentro de un sistema más amplio de apoyo a decisiones.

El modelo no pretende predecir sacks de manera específica, juzgar la calidad general de un jugador, sustituir el scouting de PFF, utilizar trayectorias posteriores al snap, tomar decisiones autónomas de alta confianza ni establecer relaciones causales entre la alineación y la presión.

2. Fuentes de datos y alcance

Los archivos fuente proceden del [dataset de Kaggle proporcionado](#).

Componente	Contenido	Función dentro del proyecto
Archivos Parquet de tracking	Posición, velocidad, dirección, orientación, eventos y frames de jugadores y balón	Creación de predictores al momento del snap
Datos de scouting PFF	Rol, alineación y resultados del pass rush	Identificación de pass rushers y definición del target
Información de equipos	Identificadores y metadatos de equipos	Validación y referencia

Los datos brutos de tracking contenían 8,314,178 filas y 16 columnas distribuidas en ocho archivos Parquet. La fuente de scouting PFF contenía 188,254 registros jugador-jugada.

Los nombres físicos de los archivos de tracking no correspondían perfectamente a las semanas reales de la NFL. Por esta razón, `actual_week` se derivó de la fecha del partido en lugar de inferirse del nombre del archivo. Esto evitó construir una separación temporal incorrecta.

El alcance disponible cubre 122 partidos de las semanas 1 a 8. Las conclusiones no deben generalizarse automáticamente a toda una temporada, otra temporada, partidos de posttemporada o un sistema de tracking diferente.

3. Validación de datos y construcción del target

3.1 Validación de las fuentes

El proceso inicial verificó que los archivos esperados estuvieran presentes y no vacíos, que los Parquet de tracking tuvieran esquemas compatibles, que cada frame contuviera exactamente 23 entidades, que las secuencias de frames no presentaran huecos inesperados, que las llaves jugador-jugada de PFF fueran completas y únicas, y que los registros de tracking y PFF coincidieran uno a uno.

Los indicadores PFF se comprobaron contra dominios binarios válidos. La ausencia estructural de valores se preservó en lugar de imputarse globalmente, y los alias históricos de equipos se conservaron como metadatos de referencia. Las observaciones inusuales se documentaron mediante controles y notas, en vez de eliminarse silenciosamente.

3.2 Selección del snap

Las variables se construyeron en el evento manual `ball_snap`, que representa el momento en que el centro inicia la jugada entregando el balón al quarterback.

De 8,557 jugadas fuente, 8,532 tenían un marcador manual válido y 25 fueron excluidas. Las filas de Pass Rush disminuyeron de 36,362 a 36,259; solamente se retiraron 103 registros, aproximadamente 0.283%. Utilizar un evento explícito evita combinar accidentalmente información previa y posterior al snap.

3.3 Target de presión

El target binario se construyó como:

```
pressure = pff_hurry OR pff_hit OR pff_sack
```

Propiedad del target	Resultado
Filas totales	36,259
Presiones positivas	4,214
Casos negativos	32,045
Prevalencia de presión	11.622%
Valores faltantes	0
Clases observadas	0 y 1

Los componentes utilizados para construir el target se excluyeron de los predictores para impedir fuga de información.

4. Tabla analítica e ingeniería de variables

La tabla analítica procesada se encuentra en `data/processed/pass_rush_analytical_table.parquet`. Contiene 36,259 filas y 70 columnas documentadas. Cada columna se asignó exactamente a un rol: identificador, metadato temporal, target, predictor o campo exclusivo de auditoría.

4.1 Contrato de predictores

El contrato aprobado contiene 50 predictores numéricos y un predictor categórico, `rusher_position_lined_up`, para un total de 51 variables en un orden almacenado permanentemente. No existían valores faltantes, valores no finitos ni predictores constantes.

4.2 Familias de variables


Familia	Ejemplos	Interpretación
Geometría rusher-quarterback	Distancia, separación longitudinal y desplazamiento lateral	Posición inicial del rusher con respecto al quarterback
Geometría rusher-balón	Posición relativa al balón	Ubicación del defensor respecto al punto del snap
Profundidad del quarterback	Posición detrás del balón	Posicionamiento inicial del quarterback
Bloqueador más cercano	Distancia y alineación direccional	Relación entre el rusher y el probable bloqueador más cercano
Movimiento	Velocidad, componentes y closing speed	Dirección e intensidad de movimiento al momento del snap
Codificación direccional	Transformaciones seno y coseno	Representación continua de ángulos circulares
Alineación PFF	<code>rusher_position_lined_up</code>	Categoría de alineación específica del dataset

Las variables numéricas se estandarizaron dentro del pipeline. La variable categórica se transformó mediante one-hot encoding. Identificadores, campos de auditoría, componentes del target, semanas y resultados se excluyeron del modelo.

5. Análisis exploratorio

5.1 Desbalance de clases y estabilidad temporal

Solamente 11.622% de las observaciones generaron presión. Por ello, un clasificador podría obtener accuracy elevada prediciendo casi siempre que no habrá presión. Se priorizó average precision porque evalúa qué tan bien las puntuaciones altas concentran la clase positiva poco frecuente.



Semana	Filas	Jugadas únicas	Positivos	Tasa de presión
1	4,988	1,172	598	11.989%
2	4,498	1,062	521	11.583%
3	4,809	1,139	606	12.601%
4	4,733	1,108	557	11.768%
5	4,681	1,105	528	11.280%
6	4,241	1,001	473	11.153%
7	3,865	913	427	11.048%
8	4,444	1,031	504	11.341%

La prevalencia permaneció dentro de un intervalo relativamente estrecho, lo que reduce la preocupación por un cambio severo de la tasa objetivo entre desarrollo y test.

5.2 Diferencias de variables al momento del snap

Variable	Media sin presión	Media con presión	Diferencia
Distancia rusher-QB	6.504	6.936	+0.433
Separación longitudinal rusher-QB	5.076	5.278	+0.203
Distancia al bloqueador más cercano	2.600	2.878	+0.278
Velocidad del rusher hacia el QB	0.229	0.299	+0.070
Closing speed rusher-QB	0.199	0.270	+0.071

Las presiones mostraron algo más de movimiento hacia el quarterback y mayor velocidad de acercamiento al snap. Estas son comparaciones descriptivas marginales, no efectos causales.

6. Diseño experimental

Una separación aleatoria de filas no representaría la predicción de semanas futuras. Se utilizaron las semanas 1-6 para entrenamiento inicial, la semana 7 para validar modelos y seleccionar el umbral, y la semana 8 para un único test final. Ninguna llave `gameId + playId` apareció en más de una partición.

La calidad probabilística se evaluó mediante average precision, ROC-AUC y log loss. Brier score se utilizó descriptivamente para calibración. Después de seleccionar el umbral se evaluaron precision, recall, F1, specificity, la tasa de predicciones positivas y la matriz de confusión.


7. Modelos baseline y avanzados

La comparación baseline incluyó un clasificador dummy basado en prevalencia, regresión logística sin ponderación y regresión logística balanceada. Los predictores numéricos se estandarizaron y la alineación se codificó mediante one-hot encoding dentro de los pipelines.

Modelo	Average precision	ROC-AUC	Log loss	Seleccionado
Dummy prior	0.110479	0.500000	0.347754	No
Regresión logística sin ponderación	0.151899	0.600006	0.342382	Sí
Regresión logística balanceada	0.151749	0.601697	0.675077	No

El modelo seleccionado utilizó `C=1.0`, `solver="lbfgs"`, `max_iter=2000`, `random_state=42` y ninguna ponderación de clases. Frente al dummy, mejoró average precision en 0.041420, equivalente a 37.49%.

Posteriormente se evaluaron Extra Trees y histogram gradient boosting mediante configuraciones bloqueadas y folds temporales secuenciales sobre las semanas 4-6.



Modelo	AP semana 7	ROC-AUC	Log loss	AP media en CV temporal
Extra Trees	0.153689	0.602314	0.341647	0.155191
Regresión logística	0.151899	0.600006	0.342382	0.154996
Histogram gradient boosting	0.145960	0.595577	0.343728	0.150105

Extra Trees obtuvo la mejor estimación puntual, pero su ganancia de AP fue solamente 0.001790. El intervalo bootstrap de 95% fue de -0.011327 a 0.014929 e incluyó el cero. Los intervalos de la ganancia en ROC-AUC y de la reducción de log loss también incluyeron cero.

Se conservó la regresión logística sin ponderación por ofrecer desempeño prácticamente equivalente, mayor interpretabilidad, implementación más sencilla y ninguna desventaja respaldada estadísticamente.

8. Selección del umbral

Las probabilidades de validación se encontraban aproximadamente entre 0.0283 y 0.4499, por lo que un umbral de 0.5 no producía ninguna predicción positiva. Se evaluaron todos los umbrales que modificaban una decisión, generando 3,865 candidatos.

La política maximizó F1 sobre la semana 7 y, en caso de empate, seleccionó el umbral más alto. Antes de abrir la semana 8 se bloqueó permanentemente:

0.12485514806532311

Multiplicador	Umbral	Precision	Recall	F1	Specificity	Tasa de predicciones positivas
0.80	0.099884	13.264%	74.707%	0.225282	39.325%	62.225%
0.90	0.112370	13.908%	61.593%	0.226920	52.647%	48.926%
0.95	0.118612	14.686%	56.440%	0.233075	59.279%	42.458%
1.00, seleccionado	0.124855	15.484%	50.585%	0.237102	65.707%	36.093%
1.05	0.131098	15.509%	42.857%	0.227754	71.001%	30.530%
1.10	0.137341	15.314%	34.895%	0.212857	76.033%	25.175%
1.20	0.149826	14.556%	23.419%	0.179533	82.926%	17.775%

Los umbrales más bajos detectan más presiones, pero generan más alertas falsas. Los más altos reducen las alertas, pero omiten más presiones reales. Con el umbral seleccionado, la semana 7 produjo 2,259 verdaderos negativos, 1,179 falsos positivos, 211 falsos negativos y 216 verdaderos positivos.

9. Evaluación final fuera de tiempo

Antes de acceder a la semana 8 se verificaron las huellas del modelo y la política, el orden de las variables, los hiperparámetros, el umbral y la receta de entrenamiento. Se exportó un manifiesto pre-test y se prohibió cualquier ajuste posterior de modelo, variables, calibración o umbral.


El pipeline final se creó clonando el modelo seleccionado en la Etapa 7 y se ajustó exactamente una vez con las semanas 1-7: 31,815 filas, 3,710 positivos y 51 predictores. Ninguna fila de la semana 8 participó en el entrenamiento.

Métrica	Validación semana 7	Test semana 8	Test menos validación
Average precision	0.151899	0.157750	+0.005851
ROC-AUC	0.600006	0.596890	-0.003117
Log loss	0.342382	0.347812	+0.005430
Precision	0.154839	0.158940	+0.004102
Recall	0.505855	0.476190	-0.029664
F1	0.237102	0.238332	+0.001230
Specificity	0.657068	0.677665	+0.020597
Tasa de predicciones positivas	0.360931	0.339784	-0.021147
Tasa real de positivos	0.110479	0.113411	+0.002933

Las métricas probabilísticas cambiaron de manera modesta. Esto respalda estabilidad temporal, aunque confirma que la discriminación absoluta sigue siendo limitada.

9.1 Matriz de confusión final

Final week-8 decisions at the locked threshold 240 of 504 pressures detected; 1,270 false alerts




Threshold = 0.124855. No model or threshold changes were made after accessing week 8.

Resultado	Conteo
Verdaderos negativos	2,670
Falsos positivos	1,270
Falsos negativos	264
Verdaderos positivos	240

El modelo detectó 240 de 504 presiones reales, equivalente a un recall de 47.619%. Solamente 15.894% de las predicciones positivas fueron correctas. Se predijo presión para 33.978% de los pass rushers, aproximadamente tres veces la tasa real de 11.341%.

9.2 Ranking y calibración



Higher deciles should concentrate more real pressures. Week 8 is shown only as final descriptive evidence.

Dataset	Tasa real	Probabilidad media	Brier score	Tasa del decil superior	Lift del decil superior
Validación semana 7	0.110479	0.117648	0.097418	0.170543	1.543670
Test semana 8	0.113411	0.115319	0.099395	0.191011	1.684234

En la semana 8, average precision fue 1.391 veces la prevalencia y el decil con mayor puntuación alcanzó una tasa de presión de 19.101%. La probabilidad media, 11.532%, fue cercana a la tasa real de 11.341%. El ranking probabilístico es, por lo tanto, más útil que la clasificación binaria por sí sola.

10. Hallazgos principales

- Existe señal, pero es modesta.** Las variables del snap mejoraron el ranking frente al baseline, aunque el ROC-AUC final permaneció por debajo de 0.60 y precision por debajo de 16%.
- El modelo sencillo estaba justificado.** Extra Trees no demostró una mejora estable sobre la regresión logística.
- La generalización temporal fue estable.** Las métricas de validación y test permanecieron cercanas y no ocurrió un colapso en la semana 8.
- El umbral favorece sensibilidad.** Recupera casi la mitad de las presiones, pero genera numerosas alertas falsas.

5. **El ranking es el uso más sólido.** Los grupos de mayor puntuación concentran más presiones que la población completa.
-

11. Limitaciones y riesgos

11.1 Alcance temporal limitado

Los datos cubren únicamente las semanas 1-8. El desempeño podría cambiar más adelante en la temporada, en playoffs o en otra temporada.

11.2 Dependencia de las etiquetas

El target hereda cualquier subjetividad, regla de cobertura o error presente en las etiquetas de scouting PFF.

11.3 Información exclusiva del snap

La presión depende de eventos posteriores, como la ejecución del bloqueo, el movimiento del quarterback, el desarrollo de las rutas y las interacciones entre jugadores. Estos elementos se excluyeron deliberadamente para conservar el momento de predicción.

11.4 Observaciones correlacionadas

Varios pass rushers pueden pertenecer a una misma jugada. La separación temporal impide que una jugada aparezca en distintas particiones, pero las filas de una misma jugada no son estadísticamente independientes. Una extensión podría utilizar remuestreo agrupado por jugada.

11.5 Objetivo del umbral

F1 no representa un costo específico de scouting o negocio. Un umbral de producción debería responder a costos operativos explícitos y seleccionarse con nuevos datos de desarrollo, nunca modificarse después de revisar la semana 8.

11.6 Precision y validez externa limitadas

La mayoría de las clasificaciones positivas fueron falsos positivos. Además, las variables, el tracking y los códigos PFF pertenecen al dataset suministrado. Utilizar el modelo en otra fuente exigiría nuevas validaciones de esquema, etiquetas, unidades, calibración y tiempo.

11.7 Ausencia de interpretación causal

Los coeficientes, diferencias de variables y tasas por alineación representan asociaciones. No demuestran que cambiar la posición o alineación de un jugador causaría una presión.

12. Reproducibilidad y controles de calidad

El entorno final utilizó Python 3.14.0, NumPy 2.5.2, pandas 3.0.5, scikit-learn 1.9.0 y joblib 1.5.3. Se utilizó `random_state=42` donde correspondía.

Notebook	Propósito
01_data_validation.ipynb	Inventario, validación de esquemas, target y exportaciones intermedias
02_analytical_table.ipynb	Ingeniería de variables al snap y validación de la tabla analítica
03_exploratory_analysis.ipynb	Análisis exploratorio y separación temporal
04_modeling_baselines.ipynb	Modelos dummy y regresión logística
05_advanced_modeling.ipynb	Modelos avanzados, CV temporal y bootstrap
06_threshold_selection.ipynb	Selección del umbral con validación y bloqueo de la política
07_final_evaluation.ipynb	Entrenamiento final controlado y evaluación única de la semana 8

La ejecución final limpia confirmó 14 de 14 marcadores PASS, 93 de 93 controles de calidad, 12 de 12 huellas de artefactos, conteos de ejecución secuenciales, cero errores y ningún ajuste posterior al test. El estado final del manifiesto fue `final_test_evaluation_completed_without_post_test_adjustment`.

Artefacto	Propósito
stage7_selected_model.joblib	Modelo seleccionado antes de ajustar el umbral
stage8_selected_policy.json	Modelo, variables, umbral y protocolo de entrenamiento bloqueados
stage9_final_model.joblib	Modelo ajustado una vez con las semanas 1-7
stage9_pretest_manifest.json	Evidencia registrada antes del acceso al test
stage9_test_predictions.parquet	Probabilidades y decisiones finales por fila
stage9_test_metrics.csv	Métricas finales
stage9_final_quality_report.csv	Los 93 controles finales
stage9_final_manifest.json	Inventario final y huellas de artefactos
report_visualizations.py	Generación reproducible de figuras

13. Conclusión

El proyecto produjo un pipeline validado y evaluado temporalmente para estimar la probabilidad de presión del pass rush al momento del snap.

La evidencia muestra que las variables de tracking contienen una señal real pero limitada; la regresión logística transparente funciona prácticamente igual que las alternativas no lineales; el desempeño permaneció estable de la semana 7 a la semana 8; y el umbral bloqueado recupera casi la mitad de las presiones, aunque genera numerosos falsos positivos.

El modelo debe posicionarse como una herramienta de priorización analítica. Puede ordenar observaciones para revisión, enriquecer el análisis de futbol americano o aportar una entrada a un sistema más amplio con contexto post-snap y experiencia de dominio.

Lo más importante es que el resultado final se obtuvo mediante un protocolo predefinido y auditable. No se modificó el modelo, las variables, los hiperparámetros, el umbral ni la calibración después de acceder a los datos de test.

Apéndice A. Definición de métricas

Métrica	Interpretación práctica
Average precision	Qué tan bien las probabilidades altas concentran las presiones poco frecuentes
ROC-AUC	Probabilidad de que una presión reciba mayor puntuación que un caso sin presión
Log loss	Penalización de probabilidades incorrectas y demasiado confiadas; menor es mejor
Precision	Proporción de presiones predichas que fueron presiones reales
Recall	Proporción de presiones reales detectadas por el umbral
F1	Media armónica entre precision y recall
Specificity	Proporción de casos sin presión clasificados correctamente
Brier score	Diferencia cuadrática media entre probabilidad y resultado; menor es mejor
Lift	Tasa de presión de un grupo dividida entre la prevalencia general

Apéndice B. Resumen del test final

Elemento	Valor final bloqueado
Modelo seleccionado	LogisticRegression_unweighted
Periodo final de entrenamiento	Semanas 1-7
Periodo de test	Semana 8
Predictores	51
Umbral de clasificación	0.12485514806532311
Filas de semana 8	4,444
Jugadas de semana 8	1,031
Positivos de semana 8	504
Average precision	0.157750
ROC-AUC	0.596890
Log loss	0.347812
F1	0.238332
Lift del decil superior	1.684234
Ajustes posteriores al test	Ninguno